



Tarea 2.

Antonia Morales

¹Departamento de Física, Universidad Técnica Federico Santa María, San Joaquín, Chile

Problema 1: Inteligencia artificial para problemas inversos

Parte (a)

Problemas directos e inversos

El **problema directo** consiste en determinar la respuesta de un sistema físico, representada por la señal $x(t)$, a partir de sus parámetros (γ, k) . Se trata de un problema donde la solución es única y presenta una dependencia continua respecto a los parámetros del sistema:

$$m\ddot{x} + \gamma\dot{x} + kx = 0 \xrightarrow{\text{directo}} x(t; \gamma, k) \quad (1)$$

donde m es la masa, γ el coeficiente de amortiguamiento y k la constante elástica.

Por otra parte, el problema inverso busca inferir los valores de los parámetros (γ, k) a partir de una señal observada $\mathbf{x} = (x(t_1), \dots, x(t_{N_t}))$. Lo cual es más complicado debido a que el mapeo del espacio de parámetros al espacio de señales, $\theta \mapsto x(t)$, no posee una inversa sencilla.

Esta dificultad surge por tres factores: la falta de unicidad (donde parámetros distintos pueden generar señales casi idénticas), la inestabilidad (pequeñas perturbaciones en la señal medida se amplifican significativamente al intentar revertir el proceso) y la presencia de ruido experimental.

Aprendizaje Supervisado

El enfoque de aprendizaje supervisado parte de un conjunto de datos formado por pares $\{\mathbf{x}_i, \boldsymbol{\theta}_i\}_{i=1}^N$, donde cada señal observada $\mathbf{x}_i$ actúa como entrada y los parámetros correspondientes $\boldsymbol{\theta}_i = (\gamma_i, k_i)$ constituyen las **etiquetas**. El objetivo del modelo es aproximar la función $f: \mathbf{x} \mapsto \boldsymbol{\theta}$.

Para resolver este problema inverso mediante aprendizaje supervisado, es necesario el conocimiento de las etiquetas ya que el modelo requiere conocer la relación entre la señal y los parámetros que la crearon. Estas etiquetas se pueden obtener con simulaciones numéricas del problema directo.

Conjuntos de entrenamiento y validación

Para garantizar que el modelo aprenda patrones generales y no solo memorice datos, el dataset se divide en dos subconjuntos:

- **Train:** utilizado durante el proceso de aprendizaje para que el modelo ajuste sus parámetros internos mediante la minimización de una función de pérdida.
- **Test:** compuesto por datos desconocidos para el modelo, lo cual permite evaluar su capacidad de generalización ante escenarios no vistos.

La evaluación solo con el conjunto de entrenamiento podría conducir al sobreajuste o overfitting, fenómeno donde el modelo captura el ruido o detalles irrelevantes de los datos de entrenamiento, perdiendo su efectividad frente a nuevos ejemplos.

Función de Pérdida

La función de pérdida cuantifica el error de predicción del modelo. La mayoría de los modelos de Machine Learning se entrenan usando Descenso del Gradiente, para esto, necesitamos que la función de pérdida sea derivable. Para esto se usa el error cuadrático medio.

$$\text{MSE} = \frac{1}{N} \sum_{i=1}^N \left[(\gamma_i - \hat{\gamma}_i)^2 + (k_i - \hat{k}_i)^2 \right] \quad (2)$$

el MSE, es utilizado ya que amplifica los errores grandes en comparación con los errores pequeños, esto obliga al modelo a corregir las predicciones muy malas o valores muy atípicos.

Parte (b)

Ejemplos de señales generadas




Figura 1: Algunas de las señales con ruido y sin ruido generadas, se observa que a mayor k la señal tiene mayor frecuencia de oscilación y a mayor γ la señal tiene mayor amortiguamiento.

Parte (c)

RandomForestRegressor

Para la configuración del modelo de RandomForestRegressor, se seleccionaron 200 estimadores dejando la profundidad máxima libre para permitir que los árboles se expandan según la complejidad de los datos, aunque restringiendo el crecimiento mediante un mínimo de 2 muestras por hoja con el objetivo de prevenir el sobreajuste y se estableció una semilla fija para asegurar la reproducibilidad de los resultados en cada ejecución y se obtuvieron los siguientes resultados:




Figura 2: γ, k reales vs reales para RandomForestRegressor

Rendimiento

	RMSE γ	RMSE k
train	0.00814	0.03460
test	0.01677	0.02612

Tabla 1: Rendimiento del modelo, el coeficiente de amortiguamiento (γ) al tener un RMSE mayor, se entiende que es más difícil de inferir debido a que si la señal observada contiene ruido, la envolvente del decaimiento se ve enmascarada, lo que dificulta que el modelo distinga entre un amortiguamiento real y las fluctuaciones estocásticas, mientras que k regula la frecuencia de oscilación la suele ser más estable.

El sobreajuste se manifiesta cuando el RMSE de entrenamiento es menor que el error de validación o prueba. En el caso de los modelos analizados, esto sucede porque el modelo ha memorizado los datos de entrenamiento en lugar de aprender la regla física que rige el sistema.

MLPRegressor

se empleó una red de tres capas ocultas con 256, 128 y 64 neuronas respectivamente, utilizando la función de activación ReLU para capturar las relaciones no lineales del sistema. El entrenamiento se llevó a cabo mediante el optimizador Adam con una tasa de aprendizaje inicial de 10^{-3} , estableciendo un límite de 500 iteraciones totales. también, se implementó una estrategia de detención temprana basada en una fracción del 10% de los datos para validación, configurando un umbral de 20 iteraciones sin mejora para finalizar el proceso y así prevenir el sobreajuste.




Figura 3: Enter Caption

	RMSE γ	RMSE k
train	0.04427	0.06339
test	0.05968	0.09362

Tabla 2: Rendimiento del modelo, en este caso para ambas γ, k se tiene un error mayor durante la validación.

Parte (d)

Efecto del ruido

Se estudió el impacto del ruido en el entrenamiento de ambos modelos para

$$\sigma = (0, 0,01, 0,02, 0,05, 0,10)$$




Figura 4: Eectos del aumento de ruido en la señal sobre el rendimiento del modelo

Se determina que γ resulta más difícil de inferir que k . La razón física es que: k controla la frecuencia de oscilación, que es un efecto observable desde el principio de la señal. γ controla el decaimiento de la amplitud, un efecto que solo se hace evidente a mayores tiempos. Con ruido, la envolvente del decaimiento queda enmascarada.



El sobreajuste se manifiesta cuando el error de entrenamiento (línea punteada) es significativamente menor que el error de validación/test (línea sólida). Ocurre porque el modelo memoriza los datos de entrenamiento, incluyendo el ruido, en lugar de aprender. Al aumentar σ el RMSE de test crece (el ruido dificulta la inferencia) y la diferencia entre train-test puede aumentar, indicando mayor sobreajuste.

El Random Forest tiende a mostrar mayor sobreajuste (RMSE train $\rightarrow 0$ para $\sigma = 0$), mientras que el MLP con early stopping lo controla mejor. para $\sigma = 0$ ambos modelos recuperan los parámetros casi perfectamente, confirmando que el problema inverso es resoluble cuando los datos son exactos. A medida que σ aumenta, el error aumenta, siendo γ el parámetro más sensible al ruido.

Problema 2: Terapia con protones

Parte (a)

Pico de Bragg:

La energía depositada en un material depende del inverso del cuadrado de la velocidad, por lo tanto, cuando la partícula está por detenerse la energía depositada tiene un máximo.

Ecuación de Bethe Bloch:

- $K = 4\pi N_A r_e^2 m_e c^2$
 N_A : Número de Avogadro ($6,022 \times 10^{23} \text{ mol}^{-1}$)
 r_e : Radio del electrón ($\approx 2,817 \times 10^{-13} \text{ cm}$).
 $m_e c^2$: Energía en reposo del electrón $\approx 0,511 \text{ MeV}$.
- z : carga de la partícula incidente en unidades de carga elemental e
- aparece debido a que cuando una partícula cargada atraviesa un material, interactúa con los electrones del material, esta interacción está descrita por la fuerza eléctrica, la cual depende de la carga de la partícula incidente y del electrón, dado que la fuerza es proporcional a la carga, el traspaso de momentum también lo es. La energía que pierde la partícula incidente es exactamente igual a la energía cinética que gana el electrón (asumiendo que el electrón estaba inicialmente en reposo). La energía cinética se relaciona con el momento transferido mediante:

$$\Delta E = \frac{(\Delta p)^2}{2m_e}$$

y ($\Delta p \propto z$)

$$\therefore \Delta E \propto z^2$$

- Z : número atómico del material absorbente
- A : masa atómica del material absorbente
- β : velocidad relativa de la partícula cargada el cambio en el momentum, Δp que recibe el electrón del material es el producto de la fuerza por el tiempo

$$\Delta p = F \Delta t$$

y

$$\Delta t = \frac{b}{v}$$

donde b es la distancia mínima entre la trayectoria de la partícula y un electrón en una colisión específica. por ende

$$\Delta p \propto \frac{1}{v} \implies \Delta E \propto \frac{1}{v^2} = \frac{1}{\beta^2 c^2}.$$

- γ : factor de Lorentz

Una carga en movimiento relativista no tiene un campo eléctrico esférico sino que el campo sufre una contracción de Lorentz en la dirección del movimiento y el campo eléctrico perpendicular a la trayectoria se vuelve mucho más intenso por un factor de γ y la partícula puede interactuar con electrones que están mucho más alejados, luego, la energía transferida a todos esos electrones más lejanos genera un término logarítmico adicional y aparece un factor de γ^2 dentro del logaritmo y hace que la energía perdida aumente cuando va a velocidades más cercanas a las de la luz.

- $m_e c^2$: energía en reposo del electrón
- T_{max} : máxima energía cinética que la partícula incidente puede transferir a un electrón libre del medio en una pura colisión;

$$T_{m\acute{a}x} = \frac{2m_e c^2 \beta^2 \gamma^2}{1 + 2\gamma \frac{m_e}{M} + \left(\frac{m_e}{M}\right)^2}$$

- I : potencial de excitación del medio

representa la energía media necesaria para excitar los electrones de los átomos del medio, I no se puede calcular fácilmente a partir de primeros principios y por lo general se utilizan tablas empíricas basadas en experimentos de dispersión de haces de partículas.

Si I es pequeño el material permite una pérdida de energía más alta porque es fácil ionizar sus electrones. Si I es grande el material es más resistente a perder energía por ionización.

Energy straggling:

Cada colisión de la partícula incidente con los átomos del medio cede una cantidad aleatoria de energía, es decir, aunque todas tengan la misma energía inicial al entrar en un material, no todas depositan la misma cantidad de energía a una distancia dada. Por lo tanto

$$\Delta E_i = \underbrace{\left(-\frac{dE}{dx}\right) \Delta x}_{\text{pérdida media}} + \underbrace{\mathcal{N}(0, \sigma_{\text{strag}} \sqrt{\Delta E_{\text{medio}}})}_{\text{fluctuación estocástica}}$$

Dispersión coulombiana múltiple:

Debido a las fuerzas de repulsión que experimenta la partícula incidente al interactuar con los átomos del material, esta sufre varias deflexiones a lo largo de su trayectoria.

Parte (b): Rango CSDA

Los valores obtenidos para el rango CSDA fueron los siguientes:

Energía MeV	CSDA calculado g/cm^2	CSDA esperado g/cm^2
50	2.222	2.227
150	15.767	15.770
250	37.931	37.940

Tabla 3: Valores calculados vs valores esperados, fuente: NIST

Parte (c): Simulación de transporte de protones sin considerar fluctuaciones estadísticas.

Se simuló el transporte de $N = 10^4$ protones con $E_0 = 150$ MeV con pasos $\Delta x = 0,1$ mm




Figura 5: Dosis depositada en función de la distancia recorrida dentro del material (gráfico normalizado).

Se identificó un máximo de la dosis para $z = 15,825$ cm, por lo que se tiene un error comparativo porcentual de $\epsilon_c = 0,36\%$ con respecto al calculado en (a) y un $\epsilon_c = 0,34\%$ con respecto al valor esperado según NIST.

Parte (d): Simulación considerando fluctuaciones estadísticas.

En la aproximación Gaussiana de Bohr:

$$\sigma_E^2 = 4\pi r_e^2 (m_e c^2)^2 N_e \frac{z^2}{\beta^2} \Delta x$$

$$4\pi r_e^2 (m_e c^2)^2 \approx 2,6 \times 10^{-25} \text{ MeV}^2 \text{ cm}^2$$

$$N_e = \rho \cdot N_A \cdot \frac{Z}{A}$$

para el agua y $\Delta x = 0,1$ mm:

$$\sigma_E^2 \approx (2,6 \times 10^{-25}) \cdot (3,34 \times 10^{23} \text{ cm}^{-3}) \cdot \frac{1}{\beta^2} \cdot (0,01 \text{ cm})$$

$$\sigma_E^2 \approx \frac{8,68 \times 10^{-4}}{\beta^2} \text{ MeV}^2$$

para un protón con $E_0 = 150 \text{ MeV}$ se tiene

$$\beta^2 \approx 0,25$$

$$\sigma_E^2 \approx \frac{8,68 \times 10^{-4}}{0,25} \approx 0,00347 \text{ MeV}^2$$

$$\sigma_E = \sqrt{0,00347} \approx \mathbf{0,059 \text{ MeV}}$$




Figura 6: Dosis normalizada depositada en función de la distancia recorrida dentro del material.

Comparando ambas señales podemos destacar que para el gráfico con fluctuaciones se destaca un ensanchamiento en la cola del pico de Bragg y se identifica el valor máximo en la dosis en $z = 15,705 \text{ cm}$

Dada la naturaleza aleatoria de las colisiones, no todos los protones se detienen a la misma distancia dentro del material, el ensanchamiento del pico, o rango straggling (σ_R), es la desviación estándar de los puntos en donde los protones se detienen, esto tiene consecuencias en la terapia con protones ya que la ventaja es la capacidad para detenerse a una profundidad específica y localizar la radiación, protegiendo los tejidos sanos detrás del tumor.

El ensanchamiento del rango puede conllevar a que se aplique dosis más allá de lo deseado, poniendo en potencial riesgo otros tejidos sanos.

Para este caso se obtuvo: $\sigma_R = 0,0837 \text{ cm}$